

Dự đoán rủi ro tín dụng bằng các mô hình máy học học thống kê

Báo cáo đồ án Học máy thống kê (DS102)

1st Hua Xuan Vinh

Faculty of Information Science and Engineering
University of Information Technology - VNU-HCM
Ho Chi Minh, Viet Nam
email 22521667@gm.uit.edu.vn

2nd Nguyen Gia Lam

Faculty of Information Science and Engineering
University of Information Technology - VNU-HCM
Ho Chi Minh, Viet Nam
email 22520740@gm.uit.edu.vn

Tóm tắt nội dung—Nghiên cứu này tập trung vào việc thiết kế và đánh giá hệ thống dự báo khả năng mất khả năng thanh toán của khách hàng dựa trên các mô hình máy học thống kê hiện đại, nhằm tối ưu hóa quy trình quản trị rủi ro tại các tổ chức tài chính. Phương pháp tiếp cận bao gồm việc xây dựng một quy trình xử lý dữ liệu phức hợp, ứng dụng kỹ thuật điều chỉnh quá mức (ví dụ: nhóm theo độ tuổi để điều chỉnh thu nhập), biến đổi logarit để xử lý phân phối lệch và tối ưu hóa ngưỡng cắt (Threshold Optimization) dựa trên chỉ số F2-score nhằm ưu tiên độ phủ (Recall) đối với các khoản vay xấu. Ba thuật toán chủ chốt bao gồm Logistic Regression, XGBoost và LightGBM đã được triển khai thực nghiệm để so sánh hiệu năng trên tập dữ liệu rủi ro tín dụng quy mô lớn. Kết quả thực nghiệm cho thấy các mô hình học máy dựa trên cấu trúc cây quyết định tăng cường (Ensemble Tree-based models) thể hiện sự vượt trội rõ rệt, trong đó XGBoost đạt chỉ số ROC AUC tối ưu ở mức 0,9476 và khả năng nhận diện nợ xấu đạt tỷ lệ 86% sau khi tinh chỉnh ngưỡng. Nghiên cứu khẳng định rằng việc kết hợp các thuật toán học máy phi tuyến tính cùng chiến lược hiệu chỉnh ngưỡng dựa trên chi phí rủi ro thực tế đóng vai trò then chốt trong việc giảm thiểu tổn thất tín dụng, cung cấp một khung tham chiếu thực tiễn cho việc triển khai các hệ thống xếp hạng tín dụng tự động trong kỷ nguyên kinh tế số.

Index Terms—Credit risk prediction, Statistical learning, Threshold optimization, Logistic Regression, LightGBM, XGBoost.

I. GIỚI THIỆU

Rủi ro tín dụng, cụ thể là khả năng khách hàng không thực hiện đúng nghĩa vụ hoàn trả nợ gốc và lãi theo thỏa thuận, đóng vai trò là yếu tố sống còn đối với sự ổn định và phát triển bền vững của các định chế tài chính trên toàn cầu. Mục tiêu cụ thể của đồ án này là nghiên cứu và xây dựng một hệ thống dự đoán xác suất vỡ nợ (Probability of Default - PD) dựa trên nền tảng các mô hình máy học thống kê hiện đại, nhằm hỗ trợ quá trình ra quyết định cho vay một cách khách quan và chính xác. Bài toán được định nghĩa dưới dạng phân loại nhị phân (Binary Classification), trong đó mô hình cần phân tách khách hàng thành hai lớp dựa trên các biến số về lịch sử tài chính, đặc điểm nhân khẩu học và hành vi tiêu dùng. Việc xác định chính xác các tham số trọng yếu như xác suất vỡ nợ cho phép các tổ chức tín dụng ước tính tổn thất dự kiến (Expected Loss

- EL) theo công thức tiêu chuẩn $EL = PD \times LGD \times EAD$ [1], từ đó tuân thủ các chuẩn mực quản trị rủi ro quốc tế như Basel.

Trên phương diện quốc tế, quá trình đánh giá rủi ro tín dụng đã trải qua sự chuyển đổi cơ cấu mạnh mẽ từ các phương pháp thống kê truyền thống như phân tích phân biệt tuyến tính (LDA) và hồi quy Logistic sang các giải pháp dựa trên dữ liệu lớn và trí tuệ nhân tạo [1], [2]. Các công trình nghiên cứu hiện đại đã chứng minh tính hiệu quả vượt trội của các thuật toán học máy dạng cây (Ensemble Tree-based models) bao gồm XGBoost, LightGBM và CatBoost trong việc khai phá các mối quan hệ phi tuyến tính phức tạp, với chỉ số diện tích dưới đường cong (AUC-ROC) thường xuyên đạt ngưỡng trên 0,90 [3]–[6]. Bên cạnh đó, các xu hướng nghiên cứu mới đang tập trung vào trí tuệ nhân tạo có khả năng giải thích (Explainable AI - XAI) nhằm cân bằng giữa độ chính xác dự báo và tính minh bạch trong các quyết định phê duyệt khoản vay, đáp ứng yêu cầu khắt khe của các cơ quan quản lý tài chính toàn cầu [7].

Tại thị trường Việt Nam, tiến trình ứng dụng máy học trong lĩnh vực tài chính ghi nhận những bước tiến chiến lược thông qua sự tiên phong của các công ty Fintech và các ngân hàng thương mại lớn. Các đơn vị tiêu biểu như MoMo đã ứng dụng hạ tầng tính toán hiệu năng cao để tối ưu hóa quy trình thẩm định trên siêu ứng dụng [8]. Các ngân hàng nội địa như VPBank cũng đã tích hợp sâu rộng các mô hình dự báo tiên tiến vào hệ thống quản trị rủi ro hàng năm nhằm kiểm soát nợ xấu và nâng cao năng lực cạnh tranh [9]. Tuy nhiên, việc triển khai thực tế vẫn đối mặt với những thách thức về tính đồng bộ của dữ liệu và hiện tượng mất cân bằng lớp (Imbalanced Data), đòi hỏi những nghiên cứu chuyên sâu về kỹ thuật tiền xử lý và tối ưu hóa thuật toán mà đồ án này sẽ tập trung giải quyết [10]–[12].

II. GIỚI THIỆU BỘ DỮ LIỆU

Tập dữ liệu được khai thác trong nghiên cứu này là "Credit Risk Dataset", một kho dữ liệu có cấu trúc mô phỏng các hoạt động cho vay thực tế với quy mô hơn 32.500 bản ghi khách hàng. Mỗi quan sát trong tập dữ liệu đại diện cho một

hồ sơ vay vốn cụ thể, được định nghĩa bởi tập hợp các thuộc tính đa chiều bao gồm cả thông tin định tính và định lượng. Biến mục tiêu quyết định của bài toán là trạng thái khoản vay (loan_status), một biến nhị phân phân loại khách hàng thành nhóm an toàn (0) và nhóm có rủi ro vỡ nợ (1). Việc sử dụng một tập dữ liệu có quy mô lớn và đa dạng các đặc trưng cho phép các mô hình máy học thống kê thực hiện quá trình huấn luyện và kiểm thử trên một không gian dữ liệu mang tính đại diện cao, từ đó nâng cao tính tổng quát hóa cho các dự báo rủi ro trong tương lai.

A. Hệ thống các đặc trưng và thuộc tính

Hệ thống các biến số trong tập dữ liệu được phân loại một cách khoa học thành ba nhóm chỉ báo cốt lõi nhằm phản ánh toàn diện năng lực và ý chí trả nợ của khách hàng.

- **Nhóm chỉ báo nhân khẩu học và kinh tế** bao gồm độ tuổi, thu nhập hàng năm, hình thức sở hữu nhà ở (Home Ownership) và thâm niên công tác (Employment Length), đóng vai trò xác định tính ổn định về tài chính và khả năng tích lũy của người vay.
- **Nhóm chỉ báo liên quan trực tiếp đến khoản vay** tập trung vào các thông số kỹ thuật như mục đích vay vốn (Loan Intent), số tiền vay (Loan Amnt), lãi suất (Loan Int Rate) và hạng tín dụng (Loan Grade) do hệ thống xếp hạng nội bộ cung cấp.
- **Nhóm chỉ báo lịch sử tín dụng** bao gồm thâm niên sử dụng tín dụng và hồ sơ về việc đã từng vỡ nợ trong quá khứ, cung cấp các bằng chứng thực nghiệm về thái độ tuân thủ nghĩa vụ tài chính của cá nhân.

Sự kết hợp giữa các nhóm biến này tạo nên một cấu trúc dữ liệu phức hợp, giúp mô hình nhận diện được các mẫu rủi ro tiềm ẩn thông qua các mối tương quan phi tuyến tính giữa lịch sử tín dụng và điều kiện kinh tế hiện tại.

B. Đặc điểm của bộ dữ liệu

Quá trình phân tích dữ liệu khám phá (EDA) cho thấy tập dữ liệu mang các đặc tính điển hình của bài toán rủi ro tài chính thực tế với sự hiện diện của dữ liệu khuyết thiếu và hiện tượng mất cân bằng lớp rõ rệt. Phân tích thống kê mô tả ghi nhận tỷ lệ dữ liệu trống tại trường lãi suất khoản vay và thâm niên công tác lần lượt chiếm khoảng 9,5% và 2,7% tổng số bản ghi, đòi hỏi các chiến lược điền khuyết dựa trên giá trị trung vị hoặc phân phối theo nhóm tương đồng để bảo toàn tính toàn vẹn của thông tin. Đồng thời, việc kiểm tra phân phối của các biến thu nhập và số tiền vay bộc lộ hiện tượng lệch phải cực hạn và sự tồn tại của các giá trị ngoại lai phi lý, chẳng hạn như độ tuổi vượt quá ngưỡng sinh học, yêu cầu các quy trình xử lý cắt tỉa và biến đổi dữ liệu nghiêm ngặt. Đặc biệt, hiện tượng mất cân bằng lớp giữa nhóm khách hàng vỡ nợ (chiếm tỷ trọng thấp) và nhóm khách hàng trả nợ đúng hạn là một thách thức trọng yếu, buộc nghiên cứu phải chuyển đổi trọng tâm đánh giá sang các chỉ số ưu tiên độ phủ (Recall) nhằm tối thiểu hóa sai lầm loại II trong quản trị rủi ro tín dụng.

III. PHƯƠNG PHÁP ĐỀ XUẤT

Đối với các bài toán yêu cầu hiệu năng tính toán cao và khả năng khai phá quan hệ phi tuyến phức tạp, các thư viện tối ưu hóa như XGBoost và LightGBM được tích hợp nhằm tận dụng sức mạnh của các thuật toán tăng cường độ dốc (Gradient Boosting). Toàn bộ quy trình từ giai đoạn tiền xử lý đặc trưng đến giai đoạn dự báo được đóng gói trong cấu trúc Pipeline, đảm bảo tính nhất quán của dòng dữ liệu và ngăn chặn hiện tượng rò rỉ thông tin (Data Leakage) giữa tập huấn luyện và tập kiểm thử.

A. Các mô hình thực nghiệm và công cụ triển khai

Thuật toán Hồi quy Logistic (Logistic Regression) được thiết lập đóng vai trò là mô hình tham chiếu (Baseline) nhờ tính đơn giản trong triển khai và khả năng cung cấp kết quả dưới dạng xác suất trực tiếp, giúp dễ dàng thiết lập các ngưỡng xếp hạng tín dụng. Nhằm nâng cao độ chính xác dự báo, nghiên cứu triển khai mô hình XGBoost, một giải pháp cây quyết định tăng cường sử dụng kỹ thuật chuẩn hóa bậc hai trong hàm mục tiêu để kiểm soát độ phức tạp của mô hình và tránh hiện tượng quá khớp. Song song đó, LightGBM được ứng dụng để tối ưu hóa thời gian huấn luyện thông qua kỹ thuật Gradient-based One-Side Sampling (GOSS), cho phép tập trung vào các mẫu dữ liệu có độ dốc lớn mà không làm mất đi tính tổng quát của phân phối dữ liệu ban đầu. Sự kết hợp giữa các lớp mô hình này cho phép đánh giá toàn diện từ các mối quan hệ tuyến tính cơ bản đến các tương tác đặc trưng đa chiều trong hồ sơ khách hàng.

B. Quy trình thực nghiệm và tối ưu hóa các siêu tham số

Hệ thống siêu tham số cho các mô hình được xác định thông qua kỹ thuật tìm kiếm theo lưới (Grid Search) kết hợp với kiểm chéo 5 lớp (5-fold Cross-validation) để đảm bảo tính ổn định của kết quả thực nghiệm. Các tham số trọng yếu bao gồm tỷ lệ học (learning_rate) được duy trì ở mức thấp từ 0,01 đến 0,1 để đảm bảo quá trình hội tụ bền vững, số lượng cây quyết định (n_estimators) dao động từ 100 đến 1000, và chiều sâu cây (max_depth) được giới hạn trong khoảng từ 3 đến 7 để kiểm soát tính phức tạp của không gian quyết định. Một cải tiến quan trọng được áp dụng là việc tích hợp tham số scale_pos_weight cho các mô hình Boosting, nhằm điều chỉnh trọng số hàm mất mát cho lớp khách hàng vỡ nợ xấu. Kỹ thuật này cưỡng chế mô hình phải trả giá cao hơn cho các lỗi phân loại nhằm khách hàng rủi ro thành an toàn, từ đó trực tiếp giải quyết thách thức do dữ liệu mất cân bằng gây ra trong lĩnh vực tín dụng.

IV. THỰC NGHIỆM

A. Tổ chức dữ liệu thực nghiệm

Để đảm bảo tính khách quan trong quá trình huấn luyện và đánh giá mô hình, tập dữ liệu được phân tách một cách hệ thống thành ba phân đoạn độc lập bao gồm tập huấn luyện (Training set), tập kiểm định (Validation set) và tập kiểm thử (Test set) theo tỷ lệ tương ứng là 70%, 10% và 20%. Quy trình phân tách này được thực hiện thông qua kỹ thuật lấy mẫu phân tầng (Stratified Sampling), một phương pháp thiết

yếu đối với các bài toán có sự mất cân bằng về nhãn như dự đoán rủi ro tín dụng. Việc áp dụng phân tầng đảm bảo rằng tỷ lệ giữa khách hàng nợ tốt và nợ xấu được duy trì đồng nhất trên cả ba tập dữ liệu, từ đó ngăn chặn hiện tượng sai lệch dự báo do cấu trúc dữ liệu không đại diện.

B. Độ đo đánh giá

Hiệu năng của các mô hình được định lượng thông qua một hệ thống các chỉ số đa chiều, trong đó diện tích dưới đường cong đặc tính hoạt động của máy thu (ROC AUC) được sử dụng làm thước đo tổng quát về khả năng phân biệt giữa hai lớp nợ. Tuy nhiên, do đặc thù của quản trị rủi ro tài chính ưu tiên việc phát hiện nợ xấu hơn là tối ưu hóa độ chính xác tổng thể, nghiên cứu đặc biệt nhấn mạnh vào chỉ số F2-score và độ phủ (Recall). Trong khi F1-score cung cấp giá trị trung bình điều hòa giữa độ chính xác (Precision) và Recall, chỉ số F2-score cho phép đặt trọng số cho Recall cao gấp hai lần so với Precision, phản ánh mục tiêu thực tiễn của các tổ chức tín dụng trong việc giảm thiểu sai lầm loại II. Công thức xác định độ phủ (Recall) được trình bày như sau:

$$Recall = \frac{TP}{TP + FN}$$

Trong đó, TP (True Positive) là số lượng nợ xấu được nhận diện đúng và FN (False Negative) là số lượng các khoản nợ xấu bị mô hình bỏ sót. Chỉ số ROC AUC được tính toán dựa trên tích phân của đường cong biểu diễn mối quan hệ giữa tỷ lệ dương tính thật (TPR) và tỷ lệ dương tính giả (FPR):

$$AUC = \int_0^1 TPR(FPR^{-1}(t))dt$$

Việc kết hợp các độ đo này cho phép nhóm nghiên cứu không chỉ đánh giá được năng lực dự báo của mô hình mà còn xác định được mức độ an toàn kinh tế khi triển khai hệ thống vào thực tế vận hành.

C. Kịch bản thực nghiệm


Tập huấn luyện đóng vai trò nền tảng để các thuật toán máy học như XGBoost và LightGBM cập nhật trọng số và học các đặc trưng rủi ro, trong khi tập kiểm định được sử dụng riêng biệt cho việc tinh chỉnh siêu tham số và đặc biệt là tối ưu hóa ngưỡng cắt xác suất dựa trên chỉ số F2-score. Cuối cùng, tập kiểm thử được giữ hoàn toàn độc lập và chỉ được sử dụng một lần duy nhất để phản ánh năng lực tổng quát hóa của mô hình trên các hồ sơ tín dụng mới chưa từng xuất hiện trong quá trình học. Để đảm bảo khả năng tái lập của các thực nghiệm khoa học, một giá trị hạt giống ngẫu nhiên (Random Seed) cố định đã được thiết lập xuyên suốt quá trình phân chia, tạo tiền đề vững chắc cho việc so sánh hiệu năng giữa các kiến trúc mô hình khác nhau một cách nhất quán.

V. KẾT QUẢ THỰC NGHIỆM

A. Kết quả thực nghiệm trước khi tối ưu các siêu tham số


Bảng I: Hiệu năng của các mô hình với tham số mặc định

Mô hình	ROC AUC	F2-score	Precision	Recall
Logistic Regression	0.8876	0.6273	0.7800	0.6000
LightGBM	0.9471	0.7957	0.8600	0.7800
XGBoost	0.9640	0.7864	0.8500	0.7700




Hình 1: Ma trận nhầm lẫn và ROC curve của Logistic Regression chưa tối ưu hóa.

1) *Đánh giá hiệu năng mô hình cơ sở:* Mô hình Hồi quy Logistic, đóng vai trò là điểm chuẩn sơ khởi, ghi nhận chỉ số ROC AUC đạt 0,8876. Tuy nhiên, phân tích chi tiết ma trận nhầm lẫn bộc lộ những hạn chế nghiêm trọng trong việc nhận diện nợ xấu thực tế. Cụ thể, trong tổng số 1.365 trường hợp vỡ nợ, mô hình chỉ xác định đúng 823 trường hợp (True Positives), đồng thời bỏ sót tới 542 trường hợp (False Negatives). Việc để lọt lưới gần 40% khách hàng rủi ro dẫn đến độ phủ chỉ đạt mức 0,60, gây ra những nguy cơ tổn thất tài chính lớn cho tổ chức tín dụng. Mặc dù mô hình duy trì được số lượng cảnh báo sai ở mức thấp với 252 trường hợp dương tính giả (False Positives), nhưng khả năng dự báo yếu đối với lớp nợ xấu khẳng định rằng các mối quan hệ tuyến tính không đủ để bao quát các kịch bản rủi ro phức tạp trong dữ liệu.



Hình 2: Ma trận nhầm lẫn và ROC curve của XGBoost trước tối ưu hóa.



Hình 3: Ma trận nhầm lẫn và ROC curve của LightGBM trước tối ưu hóa.


2) *So sánh các thuật toán Ensemble Boosting*: Sự chuyển đổi sang các thuật toán tăng cường độ dốc đã tạo ra một bước cải thiện mang tính đột phá về khả năng phát hiện rủi ro ngay từ cấu hình mặc định. Mô hình XGBoost thể hiện sự vượt trội nhất quán khi ghi nhận tới 1.065 trường hợp nợ xấu được dự báo chính xác, cao hơn đáng kể so với mức 823 của Logistic Regression. Đồng thời, số lượng lỗi bỏ sót nợ xấu (False Negatives) đã giảm mạnh từ 542 xuống còn 300 trường hợp, giúp đẩy chỉ số độ phủ lên ngưỡng 0,78. Tương tự, mô hình LightGBM cũng cho thấy hiệu năng ấn tượng với 1.049 trường hợp dương tính thật và chỉ 316 trường hợp âm tính giả. Cả hai mô hình Boosting đều chứng minh khả năng kiểm soát sai lầm loại I rất tốt khi số ca dương tính giả chỉ dao động từ 168 (XGBoost) đến 180 (LightGBM), giúp duy trì chỉ số Precision ở mức cao trên 0,85. Sự ổn định của các chỉ số này khẳng định ưu thế tuyệt đối của cấu trúc cây quyết định phân cấp trong việc tách biệt các phân đoạn khách hàng rủi ro.

3) *Phân tích sự cân bằng giữa các độ đo*: Dựa trên dữ liệu thực nghiệm từ các biểu đồ, khoảng cách về năng lực dự báo giữa XGBoost và LightGBM là rất nhỏ, tuy nhiên XGBoost hiện đang nắm giữ các chỉ số tối ưu nhất với F2-score đạt 0,7957. Việc tăng số lượng nợ xấu được nhận diện từ 823 lên 1.065 tương đương với việc tăng thêm khoảng 29,4% khả năng thu hồi vốn và giảm thiểu rủi ro cho hệ thống ngân hàng. Kết quả ma trận nhầm lẫn cho thấy các mô hình Boosting không chỉ nhạy bén hơn trong việc phát hiện nợ xấu mà còn hoạt động chính xác hơn đối với nhóm khách hàng nợ tốt, thể hiện qua việc số trường hợp âm tính thật (True Negatives) đạt mức trên 4.790 bản ghi. Những dữ liệu thực nghiệm này là cơ sở vững chắc để nghiên cứu tiếp tục triển khai các kỹ thuật tinh chỉnh siêu tham số và tối ưu hóa ngưỡng cắt xác suất, nhằm tối đa hóa chỉ số F2-score và giảm thiểu chi phí rủi ro tín dụng xuống mức thấp nhất có thể.

B. Kết quả thực nghiệm sau khi tối ưu các siêu tham số

Bảng II: Hiệu năng của các mô hình sau khi tối ưu hóa


Mô hình	ROC AUC	F2-score	Precision	Recall
LightGBM	0.9476	0.8032	0.6700	0.8600
XGBoost	0.9477	0.8050	0.7700	0.8200




Hình 4: Ma trận nhầm lẫn và ROC curve của Logistic Regression sau tối ưu hóa.

1) *Đánh giá mô hình Hồi quy Logistic sau tối ưu*: Mô hình Hồi quy Logistic ghi nhận sự cải thiện chiến lược về độ phủ (Recall) sau khi áp dụng hình thức phạt L1 (Lasso) với hệ số $C \approx 4,468$ và hạ ngưỡng cắt quyết định xuống mức 0,4282.

Quan sát ma trận nhầm lẫn cho thấy số lượng trường hợp nợ xấu được phát hiện chính xác (True Positives) đã tăng mạnh từ 823 lên 1.132 trường hợp, đồng thời giảm thiểu số ca bỏ sót rủi ro (False Negatives) xuống chỉ còn 233. Mặc dù chỉ số ROC AUC chỉ tăng nhẹ lên mức 0,8902, nhưng việc đẩy chỉ số Recall lên 0,83 là một kết quả ấn tượng đối với một mô hình tuyến tính. Tuy nhiên, sự đánh đổi xuất hiện rõ rệt khi số lượng cảnh báo sai (False Positives) gia tăng lên 1.125 trường hợp, cho thấy mô hình trở nên cực kỳ nhạy cảm và có xu hướng "thắt chặt" các quyết định cho vay để đảm bảo an toàn vốn.



Hình 5: Ma trận nhầm lẫn và ROC curve của XGBoost sau tối ưu hóa.



Hình 6: Ma trận nhầm lẫn và ROC curve của LightGBM sau tối ưu hóa.

2) *Hiệu năng vượt trội của các mô hình Ensemble Boosting sau tinh chỉnh*: Các thuật toán tăng cường độ dốc sau khi được tối ưu hóa siêu tham số đã xác lập những tiêu chuẩn mới về độ chính xác và khả năng phân tách lớp. Mô hình XGBoost, với cấu hình 314 cây và tỷ lệ học 0,0568, đã đạt được năng lực nhận diện nợ xấu cao nhất trong nghiên cứu khi xác định đúng 1.173 trường hợp rủi ro, đẩy chỉ số Recall lên mức 0,86 và ROC AUC đạt 0,9476. Trong khi đó, LightGBM thể hiện sự ưu việt về tính cân bằng giữa các độ đo khi đạt chỉ số ROC AUC cao nhất là 0,9477. Ma trận nhầm lẫn của LightGBM cho thấy một cấu trúc dự báo ổn định hơn với chỉ 327 trường hợp dương tính giả – thấp hơn đáng kể so với mức 578 của XGBoost – trong khi vẫn duy trì số lượng âm tính giả ở mức thấp (243 trường hợp). Việc đạt được chỉ số F2-score trên tập kiểm định lần lượt là 0,8032 (XGBoost) và 0,8050 (LightGBM) khẳng định rằng các mô hình học máy phi tuyến tính sau tối ưu hóa có khả năng kiểm soát rủi ro cực kỳ hiệu quả mà không gây ra quá nhiều sự phiền hà cho nhóm khách hàng an toàn.

3) *Tác động của tối ưu hóa ngưỡng cắt đối với quản trị rủi ro*: Kết quả thực nghiệm trên cả ba mô hình cho thấy việc rời bỏ ngưỡng xác suất mặc định 0,5 để tiến tới các ngưỡng tối ưu hóa (dao động từ 0,37 đến 0,43) là yếu tố quyết định đến tính thực tiễn của báo cáo. Phân tích sự dịch chuyển của các ô trong ma trận nhầm lẫn trước và sau tối ưu minh chứng cho

một chiến lược quản trị rủi ro chủ động: chấp nhận một tỷ lệ dương tính giả cao hơn để đổi lấy sự sụt giảm mạnh mẽ của các ca âm tính giả. Sự đồng nhất về hiệu năng của XGBoost và LightGBM với các chỉ số ROC AUC xấp xỉ 0,95 và Recall vượt ngưỡng 0,82 cho thấy hệ thống đã đạt đến trạng thái ổn định cần thiết. Việc kết hợp giữa khả năng khai phá đặc trưng mạnh mẽ của các thuật toán Boosting và kỹ thuật hiệu chỉnh ngưỡng dựa trên chi phí rủi ro thực tế chính là giải pháp tối ưu nhất để xây dựng các hệ thống xếp hạng tín dụng tự động trong môi trường tài chính hiện đại.

VI. PHÂN TÍCH HẠN CHẾ VÀ PHƯƠNG HƯỚNG PHÁT TRIỂN

Mặc dù các mô hình thực nghiệm, đặc biệt là XGBoost và LightGBM, đã thể hiện năng lực dự báo ấn tượng với các chỉ số ROC AUC tiệm cận mức tối ưu, việc phân tích sâu vào kết quả thực nghiệm vẫn bộc lộ những hạn chế mang tính hệ thống cần được xem xét một cách khách quan. Quá trình tối ưu hóa các mô hình này không chỉ đơn thuần là sự gia tăng về mặt con số mà còn phản ánh những sự đánh đổi mang tính chiến lược trong quản trị rủi ro tài chính thực tế.

A. Các hạn chế tồn tại trong nghiên cứu

Hạn chế trọng yếu nhất của nghiên cứu nằm ở sự đánh đổi về kinh tế khi ưu tiên chỉ số độ phủ (Recall) thông qua việc hạ thấp ngưỡng cắt quyết định. Kết quả thực nghiệm sau khi tinh chỉnh cho thấy sự gia tăng đột biến của các trường hợp dương tính giả (False Positives), đặc biệt rõ rệt ở mô hình Logistic Regression với hơn 1.125 trường hợp bị phân loại nhầm là nợ xấu. Trong bối cảnh vận hành thực tế của ngân hàng, việc duy trì một tỷ lệ dương tính giả cao đồng nghĩa với việc tổ chức sẽ từ chối một lượng lớn khách hàng tiềm năng có khả năng chi trả, dẫn đến việc sụt giảm doanh thu trực tiếp và gây ảnh hưởng tiêu cực đến trải nghiệm người dùng cũng như vị thế cạnh tranh trên thị trường. Bên cạnh đó, tập dữ liệu hiện tại vẫn mang tính chất của một lát cắt tĩnh (Snapshot), tập trung vào các thuộc tính nhân khẩu học và thông tin tài chính tại một thời điểm cố định mà chưa khai thác được các yếu tố động như hành vi chi tiêu theo chuỗi thời gian hoặc sự biến động của các chỉ số kinh tế vĩ mô. Việc thiếu vắng các dữ liệu hành vi dòng tiền có thể khiến mô hình phản ứng chậm trước các tín hiệu suy giảm khả năng tài chính của khách hàng trong các giai đoạn biến động kinh tế.

B. Phương hướng phát triển

Để khắc phục các rào cản về tính diễn giải của các mô hình "hộp đen" như XGBoost và LightGBM, hướng phát triển ưu tiên hàng đầu là tích hợp các kỹ thuật trí tuệ nhân tạo có khả năng giải thích (Explainable AI - XAI) [7]. Việc áp dụng các giá trị SHAP (Shapley Additive Explanations) hoặc phương pháp LIME [13], [14] sẽ cho phép các chuyên viên tín dụng định lượng được mức độ đóng góp của từng thuộc tính cụ thể vào quyết định từ chối khoản vay, từ đó đảm bảo tính minh bạch và tuân thủ các quy định khắt khe của ngành ngân hàng về quyền được giải thích của khách hàng. Song song đó, nghiên cứu cần mở rộng phạm vi trích xuất đặc trưng bằng cách tích hợp thêm dữ liệu hành vi và các biến số kinh tế vĩ

mô như lãi suất liên ngân hàng, tỷ lệ lạm phát và chỉ số tăng trưởng ngành để nâng cao tính dự báo trong các kịch bản thị trường khác nhau. Cuối cùng, việc thử nghiệm các kiến trúc mạng nơ-ron chuyên biệt cho dữ liệu dạng bảng như TabNet [15] hoặc các mô hình lai (Hybrid Models) kết hợp giữa sức mạnh dự báo của Boosting và tính diễn giải của cây quyết định đơn giản hứa hẹn sẽ mang lại một giải pháp toàn diện hơn, vừa tối thiểu hóa nợ xấu vừa tối ưu hóa được biên lợi nhuận cho các tổ chức tài chính.

VII. KẾT LUẬN

Nghiên cứu đã thực hiện thành công việc xây dựng và thực nghiệm hệ thống dự báo rủi ro tín dụng dựa trên các mô hình máy học thống kê hiện đại, đáp ứng mục tiêu đề ra về việc nâng cao năng lực nhận diện khách hàng có nguy cơ vỡ nợ. Thông qua quá trình phân tích so sánh, kết quả thực nghiệm khẳng định sự vượt trội của các thuật toán học máy dựa trên cấu trúc cây tăng cường (Ensemble Boosting) so với mô hình hồi quy truyền thống. Việc ứng dụng XGBoost và LightGBM không chỉ mang lại độ chính xác tổng thể cao với chỉ số ROC AUC tiệm cận mức 0,95 mà còn chứng minh khả năng khai phá hiệu quả các tương tác phi tuyến tính phức tạp trong dữ liệu tài chính, điều mà các mô hình tuyến tính đơn thuần thường bỏ sót.

Điểm nhấn quan trọng của đề án nằm ở việc triển khai chiến lược tối ưu hóa ngưỡng cắt xác suất dựa trên chỉ số F2-score, một bước đi mang tính thực tiễn cao trong quản trị rủi ro ngân hàng. Kết quả cho thấy việc điều chỉnh ngưỡng quyết định đã giúp đẩy mạnh độ phủ (Recall) đối với lớp nợ xấu lên mức trên 0,82, trực tiếp hỗ trợ các tổ chức tài chính trong việc chủ động ngăn chặn các tổn thất tín dụng tiềm tàng. Mặc dù vẫn tồn tại những thách thức về tỷ lệ dương tính giả, nghiên cứu đã thiết lập được một khung quy trình chuẩn hóa từ tiền xử lý dữ liệu, tinh chỉnh siêu tham số đến đánh giá đa chiều, cung cấp một giải pháp kỹ thuật tin cậy cho việc tự động hóa quy trình xếp hạng tín dụng trong kỷ nguyên số.

Tổng kết lại, nghiên cứu đóng góp một cái nhìn toàn diện về năng lực của các thuật toán học máy trong lĩnh vực tài chính, đồng thời mở ra những tiền đề quan trọng cho việc phát triển các hệ thống hỗ trợ ra quyết định thông minh. Những kết quả đạt được không chỉ có ý nghĩa về mặt học thuật trong việc ứng dụng toán học thống kê vào khoa học dữ liệu mà còn mang giá trị ứng dụng thực tiễn cao, giúp các định chế tài chính tối ưu hóa sự cân bằng giữa mục tiêu tăng trưởng tín dụng và yêu cầu an toàn hệ thống theo các tiêu chuẩn quốc tế.

TÀI LIỆU

- [1] I. D. Mienye, E. Esenogho, and C. Modisane, "Deep Learning for Credit Risk Prediction: A Survey of Methods, Applications, and Challenges," *Information*, vol. 17, no. 4, p. 395, Apr. 2026. [Online]. Available: <https://doi.org/10.3390/info17040395>
- [2] Svitla Systems, "Machine Learning for Credit Scoring," *Svitla Blog*, 2024. [Online]. Available: <https://svitla.com/blog/machine-learning-for-credit-scoring/>. [Accessed: May 15, 2026].
- [3] M. O. Udezi, "The Role Of Machine Learning In Enhancing Credit Risk Prediction Models For Financial Institutions," *IOSR Journal of Economics and Finance (IOSR-JEF)*, vol. 16, no. 5, ser. 4, pp. 79–87, Sept.–Oct. 2025. [Online]. Available: <https://www.iosrjournals.org/iosr-jef/papers/Vol16-Issue5/Ser-4/G1605047987.pdf>

- [4] Moody's, "Machine learning: Challenges, lessons, and opportunities in credit risk modeling," Moody's Insights, 2026. [Online]. Available: <https://www.moodys.com/web/en/us/insights/credit-risk/machine-learning-challenges-lessons-and-opportunities-in-credit-risk-modeling.html>
- [5] A. Ampountolas, T. N. Nde, P. Date, and C. Constantinescu, "A Machine Learning Approach for Micro-Credit Scoring," *Risks*, vol. 9, no. 3, p. 50, Mar. 2021. [Online]. Available: <https://doi.org/10.3390/risks9030050>
- [6] V. Chang, S. Sivakulasingam, H. Wang, S. T. Wong, M. A. Ganatra, and J. Luo, "Credit Risk Prediction Using Machine Learning and Deep Learning: A Study on Credit Card Customers," *Risks*, vol. 12, no. 11, p. 174, Nov. 2024. [Online]. Available: <https://doi.org/10.3390/risks12110174>
- [7] S. Ahmed, "Explainable AI in Credit Scoring: Balancing Accuracy and Transparency," *ResearchGate*, Oct. 2024. [Online]. Available: <https://doi.org/10.13140/RG.2.2.14652.86408>
- [8] NVIDIA, "How Vietnam's MoMo uses AI to provide financial services to millions," *NVIDIA Blog*, Aug. 2024. [Online]. Available: <https://blogs.nvidia.com/blog/momo-app-financial-service/>
- [9] Vietnam Prosperity Joint Stock Commercial Bank (VPBank), "Annual Report 2024: Approaching New Heights," Apr. 2025. [Online]. Available: https://static2.vietstock.vn/vietstock/2025/4/1/20250401_vpb_250401_annual_report_2024.pdf
- [10] T. M. Nguyen, "Deep Learning Approaches for Financial Risk Assessment: A Systematic Review," 2025, arXiv:2511.10964. [Online]. Available: <https://arxiv.org/abs/2511.10964>
- [11] INSART, "How to Build AI-Powered Credit Scoring Software: Tips from Experts," *INSART Blog*, 2023. [Online]. Available: <https://insart.com/how-to-build-ai-powered-credit-scoring-software-tips-from-experts/>
- [12] I. Javed, O. Althobaiti, and M. Ramzan, "Benchmarking Machine Learning Models for Credit Risk Prediction," *Data*, vol. 8, no. 11, p. 169, Nov. 2023. [Online]. Available: <https://doi.org/10.3390/data8110169>
- [13] S. Lundberg and S. I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems (NIPS)*, 2017, pp. 4765–4774. [Online]. Available: <https://doi.org/10.48550/arXiv.1705.07874>
- [14] T. Chen and C. Guestrin, "XGBoost: A Scalable Tree Boosting System," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016, pp. 785–794. [Online]. Available: <https://doi.org/10.1145/2939672.2939785>
- [15] S. O. Arik and T. Pfister, "TabNet: Attentive Interpretable Tabular Learning," *arXiv preprint arXiv:1908.07442*, 2019. [Online]. Available: <https://arxiv.org/abs/1908.07442>